

תוכנית פעולה צעד אחר צעד

פרויקט QR: זיהוי הריון מתמונת שתן בסמארטפון

בסיס: סינתזת מועצת חמשת המודלים (סימולציה פנימית, Perplexity, Gemini, ChatGPT)

גרסת תוכנית: v2 (מחליפה את v1 מתאריך 2026-05-04 בבוקר)

מצב נוכחי: מודל V5 ב-AUC 0.774 (כן). יעד מוגדר מחדש: רגישות חיצונית בספציפיות 0.95 ברמה של 0.70 ומעלה בתת-קבוצת השימוש המיועדת.

היקף: שלבים A עד G, כשבעה שבועות עבודה הנדסית עד החלטה אסטרטגית.

תאריך: 4 במאי 2026

מסמך זה מנחה את הביצוע. כל סטייה ממנו תתועד בקובץ ההחלטות.

תוכן עניינים

3	חלק 1: שלוש מסקנות שאסור לשכוח לרגע
3	חלק 2: שבע המטריקות שמחליפות את ה-AUC הכותרתי
4	חלק 3: השבוע הראשון - שלב A: היגיינה סטטיסטית
6	חלק 4: השבוע השני - שלב B: הפחתת רעש
8	חלק 5: שבועות שני ושלישי - שלב C: תקרת הפיצ'רים
10	חלק 6: לאורך כל הזמן - שלב D: כיול הסתברויות
11	חלק 7: החודש הראשון - שלב E: ניסוי הפלסיפיקציה
13	חלק 8: שלב F: דשבורד מטריקות + יומן החלטות
14	חלק 9: שלב G: מה להפסיק לעשות (פה אחד)
15	חלק 10: שאלת ה-Pivot האסטרטגית - ארבע אופציות
16	חלק 11: רשימת תיוג סופית להיום, השבוע, החודש
17	חלק 12: סיכום קישורים למסמכי המועצה

חלק 1: שלוש מסקנות שאסור לשכוח לרגע

מסקנה ראשונה. הסכנה הגדולה ביותר אינה דליפת משתנים שהכרת. ארבעת המקורות זיהו עצמאית סכנה חדשה ומסוכנת יותר: בחירת מודל על אותם folds שעליהם דווח ה-AUC. כלומר, ה-0.854 ממאי 3 הוא בחלקו תוצר של selection-on-folds, לא של מודל טוב. לפני כל ניסוי חדש, המספרים ההיסטוריים אינם בטוחים.

מסקנה שנייה. הספרות העדכנית משנה את היעד. אין ולו מאמר אחד מ-2018 ואילך שמראה זיהוי הריון מ-raw urine appearance בסמארטפון. כל ההצלחות בשטח (Healthy.io, Flaucher 2022) משתמשות ברצועה כימית או בכרטיס כיול פיזי. מטבולומיקה (Stanford, R=0.95) ו-NMR (שור, AUC 0.8) הראו שהאות הביולוגי קיים אך ברזולוציה מולקולרית, לא חזותית. **יעד 0.95 מ-RGB גולמי הוא ביולוגית שאפתני ללא תקדים פרסום.**

מסקנה שלישית. ההקצאה משתנה. ארבעת המקורות מסכימים שהשליש הקרוב הולך כך: 35 נקודות לנתיבים, 32 לפרוטוקול, 22 לפיצ'רים, 10 למודלינג. שני שלישים מהמאמץ הקרוב הוא איסוף וקליטה איכותית, לא ארכיטקטורת מודל. זה תיקון מהותי ל-v1 שהיה 30/25/30/15.

חלק 2: שבע המטריקות שמחליפות את ה-AUC הכותרתי

מהיום, כל דיווח ביצועים על מודל חייב לכלול את שבע המטריקות הבאות. ה-AUC לבדו הופך ללא משמעותי. דיווח חלקי נחשב לא תקף.

מטריקה	הגדרה	סף יעד
auc_cv	AUC ב-fold GroupKFold-5, ממוצע עם רווח סמך 95%	לדיווח בלבד
auc_holdout	AUC על קבוצת ה-holdout הנעולה של 25 נחקרים	המטריקה הפנימית הראשית
delta_auc_vs_confound	AUC(שתן + קונפאונדרים) פחות AUC(קונפאונדרים בלבד)	חייב 0.05 ומעלה
sens_at_spec95	רגישות בספציפיות 0.95	המטריקה החיצונית הראשית
brier	Brier score על ה-holdout	0.20 ומטה
ece	שגיאת כיול צפויה על ה-holdout	0.07 ומטה
phone_robustness	ירידת AUC בין משפחות טלפון מוכרות לבלתי מוכרות	ירידה מתחת ל-0.05

אזהרה. מהיום אין יותר השוואה בין 0.774 לבין 0.854. CI של AUC על N=101 הוא ± 0.08 עד ± 0.10 , ושני המספרים בלתי מובחנים סטטיסטית. השוואה אמיתית בין מודלים נעשית על ה-holdout בלבד.

חלק 3: השבוע הראשון - שלב A: היגינה סטטיסטית

זהו השלב שאסור לדלג עליו. בלי שלוש המשימות הבאות, אין משמעות לכל מספר שיופק מהמערכת בעתיד. סדר ביצוע מומלץ: A1 ביום ראשון, A2 ביום שני-שלישי, A3 ביום רביעי, A4 ביום חמישי.

A1 נעילת קבוצת holdout של 25 נחקרים קריטי

קובץ ליצירה: data/processed/holdout_subjects.csv | **זמן עבודה:** חצי יום | **תלוי ב:** שום דבר

מה לעשות: בחר 25 נחקרים, 12 חיוביים ו-13 שליליים, באופן מאוזן לפי גיל וטרימסטר. השתמש בזרע אקראי קבוע `HOLDOUT_SEED = 20260504`. שמור את שמות המזהים בקובץ CSV עם עמודות `subject_id`, `group`. לאחר היצירה ושמירה ל-git, אל תשנה את הקובץ לעולם.

קריטריון הצלחה: כל הריצות העתידיות של אימון יודיעו על האימון את ה-25 הללו ויעריכו עליהם רק כצעד אחרון.

מה לא לעשות: אל תסתכל על ביצועי המודל על ה-holdout עד שהמודל קפוא לחלוטין. צפייה אחת בלבד היא הבקשה. אם הוא נחשף ליותר מצפייה אחת, הוא נשרף ויש להחליפו במחזור הנתונים הבא.

A2 הרצת confound-only baseline קריטיקובץ ליצירה: `src/confound_baseline.py` | זמן עבודה: יום אחד | תלוי ב: A1

מה לעשות: בנה מודל לוגיסטי על מטא-דאטה בלבד, בלי שום פיקסל מתמונה. פיצ'רים שייכללו: גיל, `first_morning`, `coffee`, `fluids`, `has_health_condition`, `phone_model_onehot`, `gest_age_weeks`, `has_folic_acid`, `has_medications`, `has_progesterone`, `has_antibiotics`. הערך `subject_id` לפי `fold GroupKFold-5`, ודווח את כל שבע המטריקות.

קריטריון הכרעה - זה הניסוי שמכריע אם בכלל יש לנו אות בשתן:

- AUC קונפאונדרים בלבד מתחת ל-0.55: אין אות קונפאונדרים. ה-0.774 של V5 הוא בעיקר אות שתן. המשך בביטחון.
- AUC בין 0.55 ל-0.65: קונפאונדר חלש. דווח `delta_auc_vs_confound` ולא AUC גולמי.
- AUC בין 0.65 ל-0.75: קונפאונדר חזק. עבור מיד לשלב E (ניסוי חיצוני) במקום לשלב B.
- AUC מעל 0.75: V5 הוא רעש. שאלת ה-`pivot` האסטרטגית עולה מיד.

A3 audit של אגרגציה פר נחקר גבוהקובץ לבדיקה: `src/train_v2.py` - `src/features_v2.py` | זמן עבודה: חצי יום | תלוי ב: שום דבר

מה לעשות: קרא את הקוד שורה אחר שורה. כל מקום שבו מחושב `per-subject statistic` (mean, std, min, max, CV) חייב להיות אחד משני המצבים: או דטרמיניסטי לחלוטין מתוך התמונות של אותו נחקר ובלבד (בלי להשתמש בנתונים של נחקרים אחרים), או מחושב בתוך ה-`fold` בלבד (לא לפני הפיצול). הוסף הערה בקוד ליד כל אגרגציה שמתעדת איזה משני המצבים היא.

קריטריון הצלחה: פסקה אחת בתחילת `train_v2.py` שמצהירה איפה ואיך כל אגרגציה מתבצעת, עם הצהרה מפורשת שהפיצול קודם לכל סטטיסטיקה גלובלית.

אם נמצאת דליפה: תקן, הרץ V5 מחדש, והשווה את ה-AUC החדש למספר ההיסטורי. ירידה של מעל 0.03 מעידה שהמספרים ההיסטוריים היו מנופחים.

A4 הרצה מחדש של V5 תחת המשטר החדש גבוה

קובץ פלט: `reports/v5b_metrics.json` ו- `models/model_production_v5b.pkl` | **זמן עבודה:** חצי יום | **תלוי ב:** A1, A2, A3

מה לעשות: טען את V5 הקיים. שנה את הצינור כך שכל היפר-פרמטרים נבחרים בלולאה הפנימית של nested CV, וההערכה הסופית היא רק על קבוצת ה-`holdout` שנעלה ב-A1. הפעל את `dashboard_metrics.py` שתבנה ב-F1 והפק קובץ JSON עם שבע המטריות.

קריטריון הכרעה - מה לעשות אחרי שתראה את התוצאות:

- `delta_auc_vs_confound` מעל 0.10: קיים אות שכן ברור. עבור לשלב B אגרסיבית.
- `delta_auc_vs_confound` בין 0.05 ל-0.10: יש אות, חלש. עבור לשלב B אך הקדם את שלב E.
- `delta_auc_vs_confound` מתחת ל-0.05 עם CI שחוצה אפס: עצור את כל עבודות המודל. הרץ את שלב E ישר. האות לא בפיסקלים.

סוף שבוע 1. בנקודה הזו אתה יודע אם יש בכלל אות בשתן ואם המספרים ההיסטוריים שלנו היו תקפים. ההמשך תלוי בתשובה.

חלק 4: השבוע השני - שלב B: הפחתת רעש

שלב זה הוא האחיזה הכי חזקה שלנו על שיפור ה-AUC. שלושת המקורות החיצוניים ממליצים בקול אחד שזה המהלך הכי בעל ערך לפני כל ניסיון של פיצ'רים מתקדמים. ארבע משימות, מקבילות חלקית.

B1 פילוח אזור הנוזל בתמונה גבוה

קובץ ליצירה: `src/segment_cup.py` | **זמן עבודה:** יומיים | **תלוי ב:** שום דבר

מה לעשות: בכל תמונה, אתר את גבולות הכוס ופלח את אזור הנוזל בלבד. שתי גישות אפשריות. גישה כבדה: SAM-H עם נקודת `prompt` במרכז התמונה, קח את המסכה הגדולה ביותר. גישה קלה: Otsu או Watershed קלאסי על האזור הפנימי של הכוס. שמור את התמונות החתוכות תחת `data/raw/cropped/`.

למה זה חשוב: הרקע הלבן והשפת הכוס לא נושאים אות הריון. אם המודל למד דפוסים מהם, הוא למד shortcut. חיתוך ל-ROI מאלץ את המודל ללמוד מהנוזל בלבד.

צפי שיפור: 0.02 עד 0.04 ב-AUC.

B2 color constancy לפי רקע לבן גבוהקובץ ליצירה: `src/color_constancy.py` | זמן עבודה: יום אחד | תלוי ב: B1

מה לעשות: זהה את הפיקסלים הלבנים ברקע (מחוץ ל-ROI שחושב ב-B1). חשב נקודה לבנה ממוצעת. חלק כל ערוץ צבע בערך הנקודה הלבנה והכפל ב-255. שמור תמונות מנורמלות תחת `data/raw/normalized/`. עדכן את `build_index.py` להפנות לתיקיה החדשה דרך CLI flag.

למה זה חשוב: הספרות (Bustam 2023, Noor Azhar 2023) הראתה שהבדלי תאורה ו-white balance בין טלפונים הם המקור הגדול ביותר לרעש. נורמליזציה לפי הרקע הקיים בכל פריים מבטלת חלק גדול מההבדל.

צפי שיפור: 0.01 עד 0.04 ב-AUC.

B3 פיצ'רים ב-CIE Lab* וב-HSV רגילקבצים ליצירה: `src/hsv_features.py` ו-`src/cielab_features.py` | זמן עבודה: יום אחד | תלוי ב: B2

מה לעשות: חשב 12 פיצ'רים חדשים בכל תמונה. ב-CIE Lab*: L^* , a^* , b^* mean/std/min/max. ב-HSV: H, S, V mean/std/min/max. מעל לפיצ'רים החדשים, הוסף את הסף $L^* < 89.165$ כדגל בינארי לעכירות (Gemini). הביא ראיה לכך שהסף הזה מבדיל בין שתי צלול לעכור ב-AUC 0.984).

למה זה חשוב: Gemini הצביע על כך ש-Hue ב-HSV עמיד יותר משינויי תאורה מאשר RGB. ב-CIE Lab*, L^* הוא אינדיקטור עכירות מאומת בספרות. שני המרחבים הללו פשוט עדיפים על RGB גולמי למשימה שלנו.

B4 פיצ'רי פיזור בין תמונות רגילקובץ ליצירה: `src/dispersion_features.py` | זמן עבודה: יום אחד | תלוי ב: שום דבר

מה לעשות: לכל נחקר עם 3 תמונות או יותר, חשב: ΔE_{2000} בין כל זוג תמונות (mean, max), Jensen-Shannon divergence בין היסטוגרמות צבע, variance של highlight area (5% הפיקסלים הבהירים), brightness rank instability (קורלציה בין דירוגי בהירות לאורך התמונות).

למה זה חשוב: הפיצ'רים המנצחים הקיימים שלנו (g_mean_std , lab_L_std וכו') הם פיצ'רי שונות. ChatGPT הצביע על כך שזו נורת אזהרה: ייתכן שהמודל קורא meniscus, bubbles, scene physics (exposure) ולא biology. הפיצ'רים החדשים הללו מאפשרים בדיקה מפורשת: אם הם מנבאים phone_model או capture_order כמו שהם מנבאים label, זה shortcut. אם הם מנבאים label בלבד, זה אות.

סוף שבוע 2. צינור מעובד עם פילוח, נורמליזציה, פיצ'רים חדשים. הרץ את V5 מחדש על הצינור החדש ודווח את שבע המטריקות. צפה לעלייה מינורית באזור 0.02 עד 0.06 ב-auc_holdout.

חלק 5: שבועות שני ושלישי - שלב C: תקרת הפיצ'רים

זה השלב שהסימולציה שלי הייתה אופטימית מדי לגבי. ChatGPT ו-Perplexity מצננים את הציפיות. תכנן ל-3 משימות, כל אחת בעלת קריטריון נפילה ברור. אם משימה לא עוברת את הסף, זרוק אותה ועבור הלאה במקום לנסות לתקן.

C1 DINOv2 frozen embeddings רגיל

קובץ ליצירה: `src/embed_dinov2.py` | זמן עבודה: יום אחד | תלוי ב: B1, B2

מה לעשות: טען DINOv2-large או ViT-B/14 קפוא. בכל תמונה חתוכה ל-ROI: `resize` ל-518x518, נרמל לפי ImageNet stats, forward pass, וקח את ה-CLS token (1024 ממדים). מצע את ה-embeddings פר נחקר. שמור ב- `data/processed/dinov2_subject_embeddings.npy`. אמן LogisticRegression(C=0.1) על PCA-50 שמחושב בתוך כל fold.

קריטריון נפילה: אם `auc_holdout` לא עולה ב-0.02 לפחות מעל V5b, או אם variability בין folds עולה משמעותית, זרוק את המהלך. בדאטה של 101 נחקרים, learned features הם בסיכון גבוה לחפש בעיקר רעש.

C2 VideoMAE על קליפים רגיל

קובץ ליצירה: `src/embed_videomae.py` | זמן עבודה: יום אחד | תלוי ב: C1

מה לעשות: טען VideoMAE-base מ-HuggingFace. דגום 16 פריימים אחידים מכל קליפ של 10 שניות, forward pass, קח את ה-CLS token (768 ממדים). שלב עם ה-embeddings מ-C1 בייצוג מאוחד פר נחקר. **קריטריון נפילה:** אם השילוב לא עולה על C1 לבד ב-0.02 לפחות, זרוק את ה-68 VideoMAE קליפים זה דאטה קטן מדי לאות וידאו עם משמעות.

C3 פיצ'רי שאריות מנוטרלי-קונפאונדר גבוה

קובץ ליצירה: `src/nuisance_residualize.py` | זמן עבודה: יום אחד | תלוי ב: A2

מה לעשות: בתוך כל training fold בלבד, רגרס כל פיצ'ר urine על המשתנים הבאים: `phone_model`, `background_luminance`, `exposure`, `white_balance_proxy`, `first_morning`, `time_bucket` בשאריות (residuals) כפיצ'רים העיקריים, ובמשתני ה-`nuisance` עצמם כ-`covariates` נפרדים. אמן את המודל על השאריות + ה-`covariates`.

למה זה חשוב: זה הניסוי שמכריע אם ה-AUC שלנו הוא ביולוגיה או shortcut. אם residualization מוריד ביצועים בכל subgroup ובכל `phone_family`, אין shortcut, האות הוא ביולוגי. אם הוא מוריד ביצועים דרמטית, יש לנו shortcut detector ולא pregnancy detector.

קריטריון נפילה: ירידה של 0.05 ויותר ב-AUC לאחר residualization בלי שיפור באף subgroup, סימן שהאות הוא בעיקר shortcut.

חלק 6: לאורך כל הזמן - שלב D: כיול הסתברויות

שלב מקביל לשלב C. שתי משימות. שתיהן חייבות. אסור להציג שום הסתברות מהמודל לפני שכיול בוצע ודווח.

D1 isotonic calibration ודיווח Brier ו-ECE קריטי

קובץ ליצירה: `src/calibrate_model.py` | זמן עבודה: יום אחד | תלוי ב: A4

מה לעשות: עטוף את המודל הנוכחי ב- `CalibratedClassifierCV(method="isotonic", cv=5)`.
אמן על ה-`training data` בלבד. הערך על ה-`holdout`. דווח Brier score ו-ECE (Expected Calibration Error).
הוסף `diagram` אמינות (reliability diagram) לפלט הסטנדרטי של `pipeline` ההכשרה.
סף הצלחה: Brier מתחת ל-0.20, ECE מתחת ל-0.07 ב-`holdout`.
אם נכשל: אסור להפעיל מצג של "אחוז הריון" ב-UI עד שהמטריקות הללו עוברות. אפשר להציג דירוג בלבד, לא הסתברות.

D2 נעילת סף החלטה אחת ולתמיד גבוה

קובץ לעדכון: `src/inference_v2.py` | זמן עבודה: חצי יום | תלוי ב: D1

מה לעשות: בחר את סף ההחלטה פעם אחת על ה-`training data` לפי קריטריון Youden או יעד `spec=0.95`,
ושמור אותו כקבוע בקובץ הקונפיגורציה של הסקתה. אל תכייל את הסף שוב על ה-`holdout`. אסור.
למה זה חשוב: בחירת סף על ה-`holdout` שורפת אותו לאותו רגע ולא ניתן יהיה לדווח עליו תוצאה הוגנת אחר כך.

חלק 7: החודש הראשון - שלב E: ניסוי הפלסיפיקציה

אחרי שלבים A עד D יש לך מודל בסיס מנוקה ומכיל. שלב E הוא הצעד הגדול: ניסוי חיצוני שיכריע אם האות אמיתי בעולם האמיתי. עיצוב הניסוי הוא תכנון בלבד החודש הזה. ביצוע הניסוי בפועל לוקח 6 עד 8 שבועות אחרי שתאשר את העיצוב.

E1 כתיבת פרוטוקול הניסוי קריטי

קובץ ליצירה: docs/falsification_protocol_v1.md | זמן עבודה: 3 ימים

מה לעשות: כתוב מסמך פרוטוקול שכולל את כל הסעיפים הבאים. ChatGPT הציע את העיצוב הזה והסימולציה שלי תומכת בו עם תוספת אחת לרגישות.

- **גודל מדגם:** 240 נחקרים, 120 חיוביות מאומתות (4 עד 8 שבועות הריון, serum beta-hCG חיובי) ו-120 שליליות מאומתות (serum beta-hCG שלילי, אולטרסאונד היכן שזמין).
- **גיוס:** שלושה מקורות במקביל - מרפאת נשים, ערוץ פוריות / TTC, גיוס קהילתי. חובה לגייס שליליות שנוטלות חומצה פולית (אחרת supplementation יישאר shortcut התנהגותי).
- **1:1 matching בין כל זוג:** first_morning, hydration bin (specific gravity), phone_model, folic_acid use, caffeine ב-6 שעות שקדמו, age_band, time-of-day window.
- **exclusion:** hematuria גלויה, תסמיני UTI פעילים, תרופות שצובעות שתן.
- **rig פיזי:** אותה כוס, אותו מרחק, אותו mount לטלפון, אותו lightbox, אותו רקע לבן, אותו color card בפריים, אותו framing בכל דגימה.
- **צינור נעול:** מודל יחיד נבחר על בסיס תוצאות שלב D ולא משתנה במהלך גיוס וניתוח. אין retuning.
- **pre-registration:** הצינור והניתוח נרשמים ב-OSF לפני תחילת גיוס.
- **בדיקה ראשית:** AUROC subject-level של המודל הנעול עם 95% bootstrap CI.
- **סף הצלחה:** AUROC חיצוני של 0.82 ומעלה, lower 95% CI של 0.75 ומעלה, metadata-only baseline שלא עובר 0.60.
- **סף נפילה - no-go rule:** AUROC מתחת ל-0.70, או lower CI מתחת ל-0.60, או שיפור מתחת ל-0.05 מעל metadata-only baseline. במקרה כזה הפרויקט נסגר כתחליף ל-stick.
- **קוהורט מיני עוקב:** מיד אחרי הניסוי הראשי, גייס 50 עד 75 משתמשות לא מסוננות לפי סדר הגעה. אותו threshold נעול. אם discrimination או calibration קורסים שם, הניסוי הראשי לא מספיק לפריסה.
- **ניתוח רגישות (תוספת מהסימולציה):** בכל זוג matched, חשב את ההפרש within-pair בהסתברות החיזוי. אם ההפרש הממוצע אינו שונה ב-מובהקות מאפס, ייתכן שהאות נשען בעיקר על משתני ה-matching ולא על השתן עצמו.

E2 רכש ערכות לוטבוקס וכרטיסי צבע גבוה

פעולה: רכישה, לא הנדסה | זמן עבודה: שבוע (משלוח כלול) | עלות: 1500 דולר ל-300 ערכות

מה לעשות: רכוש 300 ערכות (250 לניסוי + 50 רזרבה) של lightbox קטן עם תאורה אחידה + כרטיס כיוול צבעים מודפס. AliExpress מוכר אותם בכ-5 דולר לערכה. שלח אותם למקור הגיוס לפני תחילת הגיוס.

למה זה חשוב: Healthy.io עברו 510(k) של FDA רק אחרי שהציגו שקילות מהותית למכשיר מעבדה תוך שימוש בכרטיס כיוול פיזי. בלי הכרטיס והלוטבוקס, יש בעיה גם ביצועית וגם רגולטורית בעתיד.

E3

עדכון תיעוד הגיוס הקיים רגיל

קובץ לעדכון: discovery_protocol_longitudinal_urine_imaging.md | זמן עבודה: חצי יום

מה לעשות: מזג את הפרוטוקול החדש מ-E1 לתוך מסמך הגיוס הקיים בתיקיית מחקרים. צור גרסה v2 והעבר את ה-v1 לארכיון.

חלק 8: שלב F: דשבורד מטריקות + יומן החלטות

שני קבצים. שניהם הופכים את העבודה לבקרה. אחת אופרטיבית, אחת ניהולית.

F1

דשבורד שבע המטריקות גבוה

קובץ ליצירה: src/dashboard_metrics.py | זמן עבודה: יום אחד

מה	לעשות:	כתוב	פונקציה
שמחזירה JSON עם שבע המטריקות מחלק 2. הפונקציה הזו תיקרא בסוף כל ריצת אימון. הפלט נשמר ב-reports/metrics_{name}_{date}.json	report_model(model, name, X_train, y_train, groups, X_holdout, y_holdout)		שמחזירה
שדרוג מומלץ: בנה גם פונקציה compare_models([m1, m2, m3]) שמדפיסה טבלת השוואה צד-לצד עם הדגשת הבדלים מובהקים סטטיסטית.			

F2

יומן החלטות גבוה

קובץ ליצירה: docs/decisions.md | זמן עבודה: חצי יום (תבנית)

מה לעשות: צור קובץ markdown שכל שורה בו מתעדת מהדורת מודל אחת. עמודות: תאריך, אירוע מעורר (איזה ניסוי או בקשה), קבצים שהשתנו, שבע המטריקות לפני, שבע המטריקות אחרי, החלטה (ship / revert / iterate). הוסף את הרשומה הראשונה: ההחלטות מהיום.

למה זה חשוב: תוך שלושה חודשים יהיו עשרות ניסויים והחלטות. בלי יומן מסודר, אנחנו חוזרים על טעויות ומאבדים את ההיסטוריה. עם יומן, כל מי שיצטרף לפרויקט יבין את הרציונל בעמוד אחד.

חלק 9: שלב G: מה להפסיק לעשות (פה אחד)

חמש פעולות שכל ארבעת המקורות מסכימים שצריכות להפסיק היום. אין דיון. אין ניואנס.

1. הפסק לדווח מספרי AUC שמגיעים מריצות בחירת מודל כאילו הם הערכות יציבות. כל AUC חייב לציין מאיזה split הוא בא.
2. הפסק להשוות 0.774 מול 0.854 כאילו ההפרש משמעותי. ה-CI חופפים בטווח רחב.
3. הפסק להשתמש ב-gest_age_weeks וב-has_folic_acid כפיצ'רים למשימת זיהוי בינארי. איסור קבוע. איסור גם בדיקות ablation. איסור גם "רק להשוואה". הם היעד עצמו.
4. הפסק להשתמש ב-AUC 0.95 כיעד מוגדר. החלף בנוסחה: רגישות חיצונית בספציפיות 0.95 ברמה של 0.70 ומעלה בתת-קבוצת השימוש המיועדת.
5. הפסק לפרסם או לחלוק חיצונית כל מספר כל עוד קבוצת ה-holdout לא נבדקה. כל שיתוף חיצוני (משקיע, פרסום, רשת חברתית) שכולל מספר ביצועים לפני שלב E הוא הפרת ההסכם הזה.

חלק 10: שאלת ה-Pivot האסטרטגית - ארבע אופציות

זו לא המלצה שלי, זו עמדה שעולה מארבעת המקורות. הראיות הספרותיות אומרות שייתכן שיעד "אפס חומרה, רק תמונה, AUC 0.95" אינו ביולוגית בר-השגה. השאלה הזו תוכרע על בסיס תוצאות שלבים A עד D ושלב E. עד אז, אלו ארבע האופציות שהמועצה הציגה.

אופציה	תיאור	תקדים בספרות	הזדמנות
A	להמשיך כמתוכנן עם יעד מתון יותר. רגישות בספציפיות 0.95 ברמה של 0.70 במקום AUC 0.95. מיצוב המוצר כ"אינדיקטור הסתברות" ולא "בדיקה אבחונית".	אין תקדים פרסום ל-RGB גולמי. הקירבה הקרובה ביותר היא Bustam 2023 על dehydration.	אין שינוי במודל העסקי. אבל הנכונות לסבול AUC נמוך מ-0.95 חייבת להיות מובנית מראש.
B	היברידי קל. מוסיף כרטיס כיול צבעים מודפס שהמשתמש מצרפת לתמונה. עדיין בלי רצועה כימית.	תקדים Healthy.io ל-510(k). ספרות מאששת (Noor Azhar, 2017, 2023, Ra).	חומרה מינימלית, עלות 50 סנט ליחידה. הופך את המוצר ל-software-as-a-medical-device בעל שקילות מהותית למכשיר מעבדה.
C	היברידי חזק. מוסיף רצועה כימית זולה (cents-level). שומר על "סמארטפון בלבד לקריאה".	תקדים Flacher 2022 + Healthy.io. כל ההצלחות בספרות הולכות בדרך הזו.	היכולת להגיע ל-AUC 0.95 בפועל. מאבד את הטענה "אפס חומרה". מתחרה ישיר ב-stick הקיים.
D	pivot למשימה רטובה אחרת בעלת היתכנות מוכחת. dehydration tracking, UTI screening, או gestational dating בהריון מאומת.	Bustam 2023 ל-dehydration. ספרות UTI עם 6 Stanford, AUC 0.95+ ל-metabolite dating.	ויתור על החזון הראשוני. עבודה עם dataset קיים אבל לבעיה אחרת. סיכוי גבוה יותר להצלחה מסחרית מהירה.

מה מכריע בין האופציות. תוצאות שלב A2 (confound baseline) נותנות אינדיקציה ראשונה. תוצאות שלב E (ניסוי 240 הנחקרים) נותנות הכרעה. עד אז, השקעה אגרסיבית ב-A עם אופציה ל-B ו-C ברקע היא הנתיב הסביר ביותר.

חלק 11: רשימת תיוג סופית להיום, השבוע, החודש

היום (90 דקות עבודה החלטתית)

- ☐ קרא את הסעיפים הבאים לפני כל החלטה: חלק 1 (שלוש מסקנות), חלק 2 (שבע מטריקות), חלק 9 (מה להפסיק), וחלק 10 (שאלת ה-Pivot).
- ☐ החלט: האם אתה מקבל את ההקצאה המתוקנת של 35/32/22/10 במקום 30/25/30/15?
- ☐ החלט: האם אתה מקבל את היעד המעודכן של רגישות בספציפיות 0.95 ברמה של 0.70, במקום AUC 0.95?
- ☐ החלט: האם אתה מסכים לנעול את ה-holdout של 25 הנחקרים ולא להסתכל עליו עד שהמודל קפוא?
- ☐ אם שלוש התשובות חיוביות, אשר ל-ML engineer להתחיל את משימה A1 מחר בבוקר.

השבוע (5 ימי עבודה)

- ☐ יום ראשון: A1 (נעילת holdout). חצי יום.
- ☐ יום שני-שלישי: A2 (confound baseline). יום שלם.
- ☐ יום רביעי: A3 (audit אגרגציה). חצי יום.
- ☐ יום חמישי: A4 (הרצת V5b עם המשטר החדש). חצי יום.
- ☐ סוף השבוע: קרא את שבע המטריקות של V5b והחלט אם להמשיך לשלב B או לקפץ לשלב E.

החודש (4 שבועות מלאים)

- ☐ שבוע 1: שלב A במלואו (היום).
- ☐ שבוע 2: שלב B ($B1 + B2 + B3 + B4$). שילוב צבע ופילוח.
- ☐ שבוע 2-3: שלב DINOv2, VideoMAE, residualization. C ($C1 + C2 + C3$).
- ☐ במקביל לשבועות 2-3: שלב D ($D1 + D2$). כיול וסף.
- ☐ שבוע 4: שלב E ($E1 + E2 + E3$). תכנון פרוטוקול הניסוי החיצוני, רכישת ערכות, עדכון תיעוד.
- ☐ במקביל לאורך החודש: $F1 + F2$. דשבורד ויומן.

חודשים 2 עד 3

- ☐ אם תוצאות שלבים A עד D מציגות auc_holdout מעל 0.78 עם calibration תקינה: השק את שלב E (ניסוי 240 נחקרים).

- ☐ אם תוצאות שלבים A עד D מציגות auc_holdout מתחת ל-0.74: זמן להעלות את שאלת ה-Pivot מחלק 10 בכובד ראש.
- ☐ בכל מקרה: עדכן את docs/decisions.md בכל החלטה, גדולה וקטנה.

חלק 12: סיכום קישורים למסמכי המועצה

כל המסמכים הבאים נשמרו במלואם בתיקיית הפרויקט. תוכנית הפעולה הזו מבוססת עליהם.

מסמך	תיאור	מיקום
FINAL_SYNTHESIS_REPORT	סינתזה מאסטר של כל ארבעת המקורות, 583 שורות. הנימוקים והמתודולוגיה.	llm_council_sessions/05_FINAL_SYNTHESIS_REPORT_20260504.md
ACTION_PLAN_V2	תוכנית הפעולה ההנדסית עם קוד פסאודו לכל קובץ.	ACTION_PLAN_V2_FROM_COUNCIL.md
literature_anchor	17 מאמרי מחקר עם metadata מלא.	literature_anchor_20260504.md
simulated_council_01	הסימולציה הפנימית עם 4 לנס מומחים.	llm_council_sessions/01_simulated_council_20260504.md
perplexity_response_02	תשובת Perplexity .verbatim	llm_council_sessions/02_perplexity_response_20260504.md
gemini_response_03	סקירת ספרות בעברית מ-Gemini.	llm_council_sessions/03_gemini_response_20260504.md
chatgpt_response_04	תשובת ChatGPT .verbatim (GPT-5)	llm_council_sessions/04_chatgpt_response_20260504.md
llm-council tool	הכלי של karpathy מותקן ומוכן עם 5 מודלים.	tools/llm-council/

הערה אחרונה

המסמך הזה הוא תוכנית עבודה, לא חוזה ולא חזון. כל המספרים, הספים והעיתויים בו ניתנים לעדכון ככל שתוצאות מתבררות. מה שלא ניתן לעדכון הוא העקרונות שמאחוריהם: היגינה סטטיסטית קודם, פרוטוקול לפני מודלינג, ראיות מול מספרים פנימיים. כל סטייה מהעקרונות הללו תתועד בקובץ ההחלטות.

סוף תוכנית פעולה v2. המוכנות לביצוע מתחילה מחר בבוקר.